

Deep Multi-View Spatial-Temporal Network for Taxi Demand Prediction

2020年12月11日

开源情况



●开源代码:无

●数据集:

- ✓数据来源于大规模的在线出租车请求数据集(滴滴出行)
- ✓ 02/01/2017-03/26/2017广州用车请求(日均30w次)
- ✓数据包含20*20个区域,每个区域大小为0.7km*0.7km
- ✓数据特征:时间特征(后四个时间间隔的平均需求值)、空间特征(区域中心的经度纬度)、气象特征(天气条件)、事件特征(节日)。

简介&&主要贡献



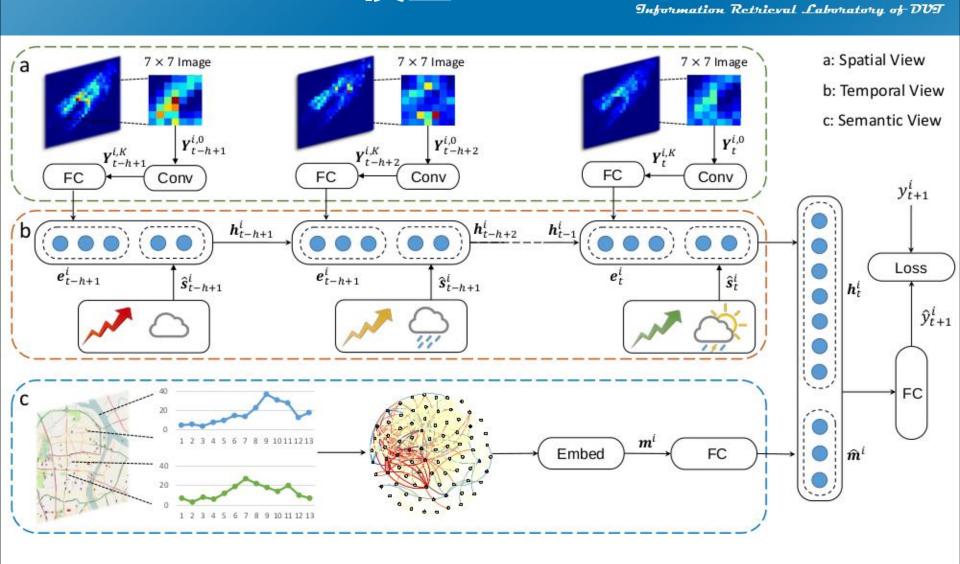
- 城市交通拥堵问题严重
- 使用智能出租车服务缓解交通压力、合理分 配资源、避免资源浪费
- 使用历史出租车请求数据来预测未来时间戳中某个区域的出租车请求数量
- 利用CNN和LSTM模型,捕获是时间和空间的非线性关系

简介&&主要贡献



- 将城市看作图像,使用局部CNN根据距离 过滤远端弱相关区域
- 使用区域图捕获语义信息(两个地点在空间上遥远但在需求上相似)
- 提出了一个统一的多视图模型,共同考虑空间、时间和语义关系

DMVST-Net模型



DMVST-Net模型



● 可空间部分:

- ◆使用本地CNN来捕获附近区域之间的依赖关系
- ◆使用K个卷积层+1个FC层
- ●时间部分: LSTM模型
- 语义部分:
 - ◆构建区域的权重图(权重表示功能相似度)
 - ◆节点被编码为向量

DMVST-Net模型



● 训练流程:

Algorithm 1: Training Pipeline of DMVST-Net

```
Input: Historical observations: \mathcal{Y}_{1,\dots,t}^L; Context
              features: \mathcal{E}_{t-h,\ldots,t}^L; Region structure graph
              G = (V, E, D); Length of the time period h;
    Output: Learned DMVST-Net model
 1 Initialization:
 2 for \forall i \in L do
         Use LINE on G and get the embedding result \mathbf{m}^{i};
         for \forall t \in [h, T] do
              S_{spa} = [\mathbf{Y}_{t-h+1}^{i}, \mathbf{Y}_{t-h+2}^{i}, ..., \mathbf{Y}_{t}^{i}];
              S_{cox} = [\mathbf{e}_{t-h+1}^{i}, \mathbf{e}_{t-h+2}^{i}, ..., \mathbf{e}_{t}^{i}];
              Append \{S_{spa}, S_{cox}, \mathbf{m}^i\}, y_{t+1}^i > \text{to } \Omega_{bt};
         end
 9 end
   Initialize all learnable parameters \theta in DMVST-Net;
11 repeat
         Randomly select a batch of instance \Omega_{bt} from \Omega;
12
         Optimize \theta by minimizing the loss function Eq. (9)
13
           with \Omega_{bt}
14 until stopping criteria is met;
```

空间视角: Local CNN



- ●使用K个卷积层+1个FC
- 巻积核大小为7*7
- FC获取空间视角向量表示:

$$\hat{\mathbf{s}}_t^i = f(W_t^{fc} \mathbf{s}_t^i + b_t^{fc}),$$

时间视角: LSTM



- 当前时刻输入:空间视角向量、天气向量拼接
- LSTM计算方式

$$\begin{aligned}
\mathbf{i}_{t}^{i} &= \sigma(\mathbf{W}_{i}\mathbf{g}_{t}^{i} + \mathbf{U}_{i}\mathbf{h}_{t-1}^{i} + \mathbf{b}_{i}), \\
\mathbf{f}_{t}^{i} &= \sigma(\mathbf{W}_{f}\mathbf{g}_{t}^{i} + \mathbf{U}_{f}\mathbf{h}_{t-1}^{i} + \mathbf{b}_{f}), \\
\mathbf{o}_{t}^{i} &= \sigma(\mathbf{W}_{o}\mathbf{g}_{t}^{i} + \mathbf{U}_{o}\mathbf{h}_{t-1}^{i} + \mathbf{b}_{o}), \\
\theta_{t}^{i} &= \tanh(\mathbf{W}_{g}\mathbf{g}_{t}^{i} + \mathbf{U}_{g}\mathbf{h}_{t-1}^{i} + \mathbf{b}_{g}), \\
\mathbf{c}_{t}^{i} &= \mathbf{f}_{t}^{i} \circ \mathbf{c}_{t-1}^{i} + \mathbf{i}_{t}^{i} \circ \theta_{t}^{i}, \\
\mathbf{h}_{t}^{i} &= \mathbf{o}_{t}^{i} \circ \tanh(\mathbf{c}_{t}^{i}).
\end{aligned}$$

语义视角: 结构嵌入



- ●使用位置图表示区域间的功能(语义)相似性
- 使用平均每周需求时间序列作为需求模式
- 每两个区域均可达,为全连接图
- 获取Embedding向量+FC

$$\hat{\mathbf{m}}^i = f(W_{fe}\mathbf{m}^i + b_{fe})$$

模型总体输出



- 拼接语义视角Embedding向量+LSTM输出
- 过FC, 使用损失函数进行训练

$$\mathcal{L}(\theta) = \sum_{i=1}^{N} ((y_{t+1}^{i} - \hat{y}_{t+1}^{i})^{2} + \gamma (\frac{y_{t+1}^{i} - \hat{y}_{t+1}^{i}}{y_{t+1}^{i}})^{2})$$

评价指标&&数据集划分



MPAE, RMSE

$$MAPE = \frac{1}{\xi} \sum_{i=1}^{\xi} \frac{|\hat{y}_{t+1}^i - y_{t+1}^i|}{y_{t+1}^i},$$

$$RMSE = \sqrt{\frac{1}{\xi} \sum_{i=1}^{\xi} (\hat{y}_{t+1}^{i} - y_{t+1}^{i})^{2}},$$

● 数据集划分:

◆训练集: 2017年2月1日-2017年3月19日

◆测试集: 2017年3月20日-2017年3月26日

◆使用前8个时间间隔(即4小时)来预测下一个时间间隔的出租车需求

实验结果一总体结果对比



Method	MAPE	RMSE
Historical average	0.2513	12.167
ARIMA	0.2215	11.932
Ordinary least square regression	0.2063	10.234
Ridge regression	0.2061	10.224
Lasso	0.2091	10.327
Multiple layer perceptron	0.1840	10.609
XGBoost	0.1953	10.012
ST-ResNet	0.1971	10.298
DMVST-Net	0.1616	9.642

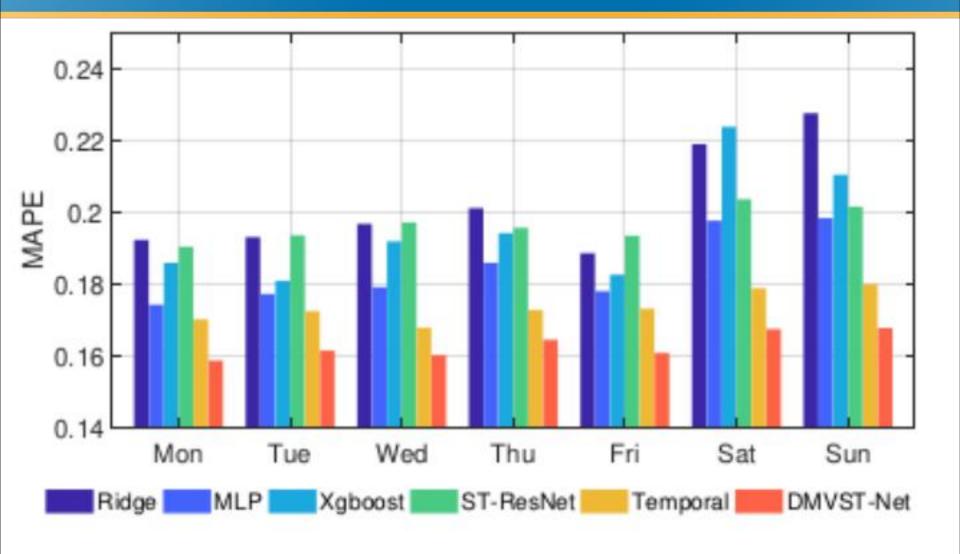
实验结果一消融实验结果



Method	MAPE	RMSE
Temporal view	0.1721	9.812
Temporal + Semantic view	0.1708	9.789
Temporal + Spatial (Neighbor) view	0.1710	9.796
Temporal + Spatial (LCNN) view	0.1640	9.695
DMVST-Net	0.1616	9.642

实验结果一按日期结果对比

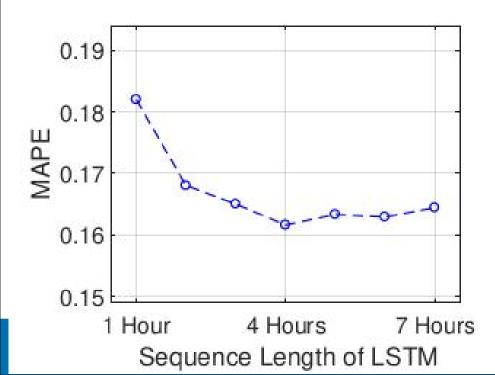


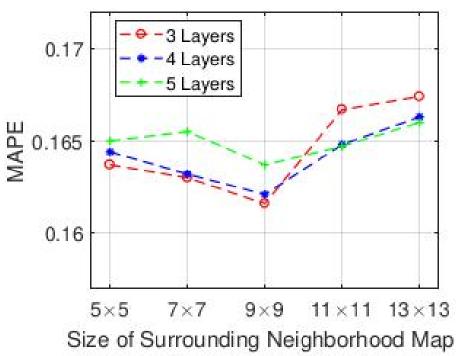


实验结果



- 巻积核大小选择: 9*9
- 巻积层层数:三层
- ●LSTM时间长度选择: 4h







- 提出统一的多视图模型 (时间、空间语义)
- ●下一步研究方向:
 - ◆ 计划合并更明确的信息(POI信息)
 - →获取可解释性更高的算法

谢谢! 请多提意见!





http://ir.dlut.edu.cn